

# Odločitvena drevesa in pravila

Ljupčo Todorovski  
Univerza v Ljubljani, Fakulteta za upravo

Marec 2018

# Pregled predavanja

## Odločitvena drevesa

- Algoritem za učenje dreves *TDIDT*
- Sprotno in naknadno rezanje dreves
- Kontrola predsodka in variance

## Odločitvena pravila

- Algoritem za učenje posameznih pravil
- Prekrivni algoritem za učenje množice pravil
- Kontrola predsodka in variance

# Zgradba odločitvenih dreves

## Notranje vozlišče

Testira vrednost izbrane napovedne spremenljivke  $X$ , npr.  $X_1 < 0.5171$

## Veje

Ustrezajo izidom testa, npr. *True* in *False*


## Končno vozlišče

Poda napoved ciljne spremenljivke  $Y$ , npr.  $\hat{Y} = 0.39$

# Napoved odločitvenega drevesa za podan primer


- Začni v korenskem vozlišču
- Ponavljaj dokler si v notranjem vozlišču
  - Opravi test notranjega vozlišča
  - Sledi veji, ki ustreza izidu opravljenega testa do novega vozlišča
- Uporabi končno vozlišče za napoved

# Primer regresijskega drevesa




$$Y = (1 + X_1 + X_1 X_2)/3 + \mathcal{N}(0, 0.05), D_i = [0, 1], i = 1..2, D_Y = [0, 1]$$

# Napovedi regresijskega drevesa




# Primer klasifikacijskega drevesa



$Y = I((1 + X_1 + X_1X_2)/3 \geq 0.5)$ ,  $D_i = [0, 1]$ ,  $i = 1..2$ ,  $D_Y = \{0, 1\}$   
 zamenjamo vrednost  $Y$  0.05 naključno izbranim primerom

# Napovedi klasifikacijskega drevesa





# Algoritem $TDIDT(S) = DecisionTree$

*TDIDT: Top-Down Induction of Decision Trees*

```
function  $TDIDT(S)$   
  if  $Impurity(S) = 0$  return  $DecisionTree(leaf : S)$   
   $Split = SelectOptimal(S)$   
   $\{S_1, S_2, \dots S_s\} = Partition(S, Split)$   
  for  $i = 1$  to  $s$  do    $t_i = TDIDT(S_i)$   
  return  $DecisionTree(node : Split, descendants : (t_1, t_2, \dots t_s))$ 
```

# Testi in razbitje množice $Partition(S, Split)$

Diskretna spremenljivka  $X_j, D_j = \{v_1, v_2, \dots, v_m\}$

- ① *Split*  $X_j$ :  $S_i = \{(\mathbf{x}, y) \in S : x_j = v_i\}$ , eno možen test
- ② *Split*  $X_j \in V, V \subset D_j, V \neq \emptyset$ :  $S_1 = \{(\mathbf{x}, y) \in S : x_j \in V\}$ ,  
 $S_2 = S \setminus S_1, 2^{|D_j(S)|-1} - 1$  možnih testov

Numerična spremenljivka  $X_j, D_j \subseteq \mathbb{R}$

*Split*  $X_j < v$ :  $S_1 = \{(\mathbf{x}, y) \in S : x_j < v\}$ ,  $S_2 = S \setminus S_1, |D_j(S)| - 1$  možnih testov (vrednosti praga  $v$ )

$D_j(S)$  je množica vrednosti  $X_j$  v množici  $S$ .

# Napoved končnega vozlišča *leaf* : $S$

Regresija,  $D_Y \subseteq \mathbb{R}$ : povprečje

$$\text{Prediction}(\text{leaf} : S) = \frac{1}{|S|} \sum_{(x,y) \in S} y$$

Klasifikacija,  $D_Y = \{v_1, v_2, \dots, v_c\}$ : večinski razred

$$\text{Prediction}(\text{leaf} : S) = \arg \max_{v \in D_Y} p(Y = v_i | S)$$

$p(Y = v_i | S)$  je verjetnost, da primer iz množice  $S$  pripada razredu  $v_i$ .

## Funkcija nečistoče $Impurity(S)$

Funkcija nečistoče meri varianco vrednosti ciljne spremenljivke  $Y$  v  $S$ .

Regresija,  $D_Y \subseteq \mathbb{R}$

$$Impurity(S) = \frac{1}{|S|} \sum_{(x,y) \in S} (y - \bar{y})^2$$

Klasifikacija,  $D_Y = \{v_1, v_2, \dots, v_c\}$

$$Impurity(S) = \phi(p_1, p_2, \dots, p_c)$$


Verjetnosti  $p_i = p(Y = v_i | S)$

# Zaželeni lastnosti funkcije nečistoče $\phi(p_1, p_2, \dots, p_c)$

- Doseže maksimalno vrednost pri enakomerni porazdelitvi  $\forall i : p_i = 1/c$
- Doseže minimalno vrednost pri porazdelitvah, kjer  $\exists i : p_i = 1$
- Simetrična: neobčutljiva na vrstni red parametrov
- Konkavna, zvezna in zvezno odvedljiva

# Dve pogosto uporabljani funkciji

- 1 Entropija  $\phi(p_1, p_2, \dots, p_c) = -\sum_{i=1}^c p_i \log_2 p_i$
- 2 Indeks Gini  $\phi(p_1, p_2, \dots, p_c) = 1 - \sum_{i=1}^c p_i^2$



# Izbira optimalnega testa $Split = SelectOptimal(S)$

Ciljna funkcija za optimizacijo zmanjšanje nečistoče  $IR$

$$IR(Split, S) = Impurity(S) - \sum_{i=1}^s \frac{|S_i|}{|S|} Impurity(S_i)$$

- Test  $Split$  povzroči razbitje  $S$  na  $\{S_1, S_2, \dots, S_s\}$
- $IR = Impurity Reduction$

Test izberemo z optimizacijo

$$\max_{Split} IR(Split, S) = \min_{Split} \sum_{i=1}^s \frac{|S_i|}{|S|} Impurity(S_i)$$

# Ali lahko prepoznam delfina?

primer	dolzina	skрге	kljun	zob	delfin
x <sub>1</sub>	3	ne	da	veliko	da
x <sub>2</sub>	4	ne	da	veliko	da
x <sub>3</sub>	3	ne	da	malo	da
x <sub>4</sub>	5	ne	da	veliko	da
x <sub>5</sub>	5	ne	da	malo	da
x <sub>6</sub>	5	da	da	veliko	ne
x <sub>7</sub>	4	da	da	veliko	ne
x <sub>8</sub>	5	da	ne	veliko	ne
x <sub>9</sub>	4	da	ne	veliko	ne
x <sub>10</sub>	4	ne	da	malo	ne



# Opis naloge strojnega učenja

## Primeri

10 opazovanih živali, od tega 5 delfinov

## Spremenljivke

- Ciljna spremenljivka  $Y = \text{deflin}$ ,  $D_Y = \{da, ne\}$
- Ena numerična napovedna spremenljivka  $X_1 = \text{dolzina}$ ,  $D_1 = \mathbb{R}^+$
- Tri diskretne napovedne spremenljivke
  - $X_2 = \text{skрге}$ ,  $D_2 = \{da, ne\}$
  - $X_3 = \text{kljun}$ ,  $D_2 = \{da, ne\}$
  - $X_4 = \text{zob}$ ,  $D_2 = \{\text{veliko}, \text{malo}\}$

Napovedni model, ki razpoznava delfine: klasifikacijsko drevo

# Nečistost množice in možni testi

$$\text{Impurity}(S), S = \{x_1, x_2, \dots, x_{10}\}$$

- $p(\text{delfin} = da) = p(\text{delfin} = ne) = 5/10 = 0.5$
- $\text{Gini}(S) = 1 - (0.5^2 + 0.5^2) = 0.5$

## Pet možnih testov

- 1  $\text{dolzina} < 4$
- 2  $\text{dolzina} < 5$
- 3  $\text{skрге}$
- 4  $\text{kljun}$
- 5  $\text{zob}$

## Test $dolzina < 4$

$Impurity(S_1), S_1 = \{x_1, x_3\}$

- $p(delfin = da) = 2/2 = 1, p(delfin = ne) = 0/2 = 0$
- $Gini(S_1) = 1 - (1^2 + 0^2) = 0$

$Impurity(S_2), S_2 = \{x_2, x_4, x_5, x_6, x_7, x_8, x_9, x_{10}\}$

- $p(delfin = da) = 3/8 = 0.375, p(delfin = ne) = 5/8 = 0.625$
- $Gini(S_2) = 1 - (0.375^2 + 0.625^2) = 0.46875$

$$IR(dolzina < 4) = 0.5 - \left( \frac{2}{10} 0 + \frac{8}{10} 0.46875 \right) = 0.125$$

## Test *dolzina* < 5

$Impurity(S_1), S_1 = \{x_1, x_2, x_3, x_7, x_9, x_{10}\}$

- $p(delfin = da) = 3/6 = 0.5, p(delfin = ne) = 3/6 = 0.5$
- $Gini(S_1) = 1 - (0.5^2 + 0.5^2) = 0.5$

$Impurity(S_2), S_2 = \{x_4, x_5, x_6, x_8\}$

- $p(delfin = da) = 2/4 = 0.5, p(delfin = ne) = 2/4 = 0.5$
- $Gini(S_2) = 1 - (0.5^2 + 0.5^2) = 0.5$

$$IR(dolzina < 5) = 0.5 - \left(\frac{6}{10}0.5 + \frac{4}{10}0.5\right) = 0$$

# Test skрге

$$\text{Impurity}(S_1), S_1 = \{x_6, x_7, x_8, x_9\}$$

- $p(\text{delfin} = da) = 0/4 = 0, p(\text{delfin} = ne) = 4/4 = 1$
- $\text{Gini}(S_1) = 1 - (0^2 + 1^2) = 0$

$$\text{Impurity}(S_2), S_2 = \{x_1, x_2, x_3, x_4, x_5, x_{10}\}$$

- $p(\text{delfin} = da) = 5/6 = 0.833, p(\text{delfin} = ne) = 1/6 = 0.167$
- $\text{Gini}(S_2) = 1 - (0.833^2 + 0.167^2) = 0.278$

$$IR(\text{skрге}) = 0.5 - \left( \frac{4}{10} 0 + \frac{6}{10} 0.278 \right) = 0.333$$

# Test *kljun*

$$\text{Impurity}(S_1), S_1 = \{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_{10}\}$$

- $p(\text{delfin} = da) = 5/8 = 0.625$ ,  $p(\text{delfin} = ne) = 3/8 = 0.375$
- $\text{Gini}(S_1) = 1 - (0.625^2 + 0.375^2) = 0.46875$

$$\text{Impurity}(S_2), S_2 = \{x_8, x_9\}$$

- $p(\text{delfin} = da) = 0/2 = 0$ ,  $p(\text{delfin} = ne) = 2/2 = 1$
- $\text{Gini}(S_2) = 1 - (0^2 + 1^2) = 0$

$$\text{IR}(\text{kljun}) = 0.5 - \left( \frac{8}{10} 0.46875 + \frac{2}{10} 0 \right) = 0.125$$

# Test zob

$$\text{Impurity}(S_1), S_1 = \{x_1, x_2, x_4, x_6, x_7, x_8, x_9\}$$

- $p(\text{delfin} = da) = 3/7 = 0.4286$ ,  $p(\text{delfin} = ne) = 4/7 = 0.5714$
- $\text{Gini}(S_1) = 1 - (0.4286^2 + 0.5714^2) = 0.4898$

$$\text{Impurity}(S_2), S_2 = \{x_3, x_5, x_{10}\}$$

- $p(\text{delfin} = da) = 2/3 = 0.667$ ,  $p(\text{delfin} = ne) = 1/3 = 0.333$
- $\text{Gini}(S_2) = 1 - (0.667^2 + 0.333^2) = 0.444$


$$IR(\text{zob}) = 0.5 - \left( \frac{7}{10} 0.4898 + \frac{3}{10} 0.444 \right) = 0.0238$$

# Izbira optimalnega testa: *skrge*


- ① *dolzina* < 4: 0.125
- ② *dolzina* < 5: 0
- ③ *skrge*: **0.333**
- ④ *kljun*: 0.125
- ⑤ *zob*: 0.0238



# Delni rezultat




# Rekurzija ...



# Končni rezultat

Legenda: *skрге = b* pomeni *skрге = ne*, *zob = b* pomeni *zob = veliko*



# Kontrola predsodka in variance

## Velikost drevesa

Kontroliramo tako, da dopuščamo  $Impurity > 0$  v končnih vozliščih.

## Rezanje dreves

- Sprotno rezanje: omejimo navzdol število primerov v vozlišču drevesa (parameter `minsplit`, *ms*)
- Naknadno rezanje: pretvarjanje notranjih vozlišč v končne

# Naknadno rezanje dreves

## Rezanje poddrevesa v vozlišču $t$

Notranje vozlišče  $t$  spremenimo v končno vozlišče  $t_L$ .

## Napaka poddrevesa $t$

$$Err_{\alpha}(t) = Err(t) + \alpha|t|$$

- $Err(t)$ : napaka poddrevesa v  $t$  na učnih primerih iz  $t$
- $|t|$ : število končnih vozlišč, ki so nasledniki  $t$

## Odločitev o rezanju: $Err_{\alpha}(t_L) \leq Err_{\alpha}(t)$

Parameter  $\alpha$ : regulator moči, stopnja rezanja (R implementacija: *cp*)

# Primer rezanja poddrevesa $Err(t : dolzina < 3.5)$

## Napaka poddrevesa

$Err_{\alpha}(t) = 0 + 3\alpha$ , poddrevo ima napako 0 in tri končna vozlišča.


## Napaka končnega vozlišča

$Err_{\alpha}(t_L) = 1/3 + 1\alpha$ , učni primeri  $\{x_3, x_5, x_{10}\}$ : dva pozitivna in en negativen (napaka 1/3).


## Prelomna točka $Err_{\alpha}(t) = Err_{\alpha}(t_L)$

Če je  $\alpha \geq 1/6$ , potem bo poddrevo porezano; sicer pa ne.

Legenda:  $skрге = b$   
pomeni  $skрге = ne$ ,  
 $zob = b$  pomeni  
 $zob = veliko$




# Regresijska drevesa: *ms* in *cp*



$$Y = (1 + X_1 + X_1 X_2)/3 + \mathcal{N}(0, 0.05), D_i = [0, 1], i = 1..2, D_Y = [0, 1]$$

# Regresijska drevesa ( $cp = 0$ ): $ms$


Številke: število končnih vozlišč v drevesu






# Regresijska drevesa ( $ms = 10$ ): $cp$

Številke: število končnih vozlišč v drevesu

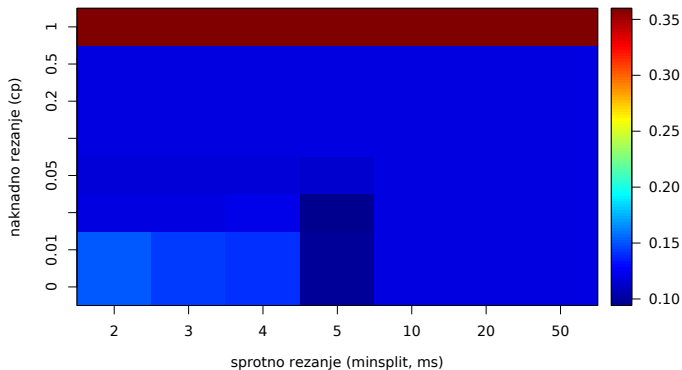


# Regresijska drevesa: število napovednih spremenljivk

Številke: število napovednih spremenljivk v drevesu



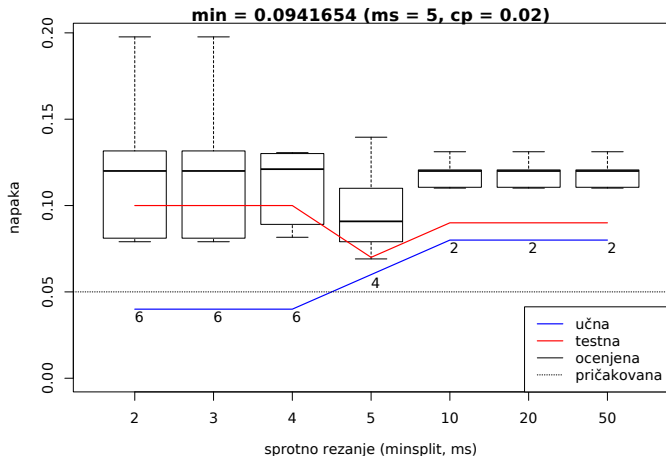
# Klasifikacijska drevesa: *ms* in *cp*



$Y = I((1 + X_1 + X_1 X_2)/3 \geq 0.5)$ ,  $D_i = [0, 1]$ ,  $i = 1..2$ ,  $D_Y = \{0, 1\}$   
 zamenjamo vrednost  $Y$  0.05 naključno izbranim primerom


# Klasifikacijska drevesa ( $cp = 0.02$ ): *ms*

Številke: število končnih vozlišč v drevesu




# Klasifikacijska drevesa ( $ms = 5$ ): cv

Številke: število končnih vozlišč v drevesu



# Klasifikacijska drevesa: število napovednih spremenljivk

Številke: število napovednih spremenljivk v drevesu



# Časovna zahtevnost algoritmov za učenje dreves

## Učenje drevesa iz podatkovne množice $S$

- Eno vozlišče:  $O(p|S|)$ ,  $p$  je število napovednih spremenljivk
- Celotno drevo:  $O(p|S| \log |S|)$ , ker je  $\log |S|$  pričakovana globina

## Naknadno rezanje

- Eno vozlišče:  $O(\log |S|)$
- Celotno drevo:  $O(\log |S| \log |S|)$

# Znani algoritmi in implementacije

CART (Breiman in ost. 1984)

Na voljo knjižnica za R.

C4.5 (Quinlan 1995), pozneje C5.0

Na voljo v zbirki Weka kot J4.8 (C4.5), na voljo knjižnica za R (C5.0).



# Kaj so odločitvena pravila?

## Eno pravilo $r$ : *IF Pogoj THEN Napoved*

- Pogoj je konjunkcija testov napovednih spremenljivk  $X$ ,  
npr.  $X_1 > 3 \wedge X_3 = ne$
- Napoved poda napovedano vrednost ciljne spremenljivke  $Y$ ,  
npr.  $\hat{Y} = da$

## Urejena (tudi zveržena) množica pravil

Napoved za  $\mathbf{x}$  poda prvo pravilo  $r$ , za katerega velja:  $Pogoj(\mathbf{x}) = True$ .

## Neurejena množica pravil

Napovedi za  $\mathbf{x}$  podajo vsa pravila  $r$ , za katera velja  $Pogoj(\mathbf{x}) = True$ , množica napove povprečje (regresija) ali večinsko napoved (klasifikacija).

# Primeri množice pravil

## Urejena množica pravil

*IF skрге = da THEN delfin = ne ELSE*  
*IF zob = veliko THEN delfin = da ELSE*  
*IF dolzina = 4 THEN delfin = ne ELSE*  
*delfin = da*

## Neurejena množica pravil

*IF dolzina = 3 THEN delfin = da*  
*IF skрге = ne  $\wedge$  zob = veliko THEN delfin = da*

# Učenje enega pravila $LearnRule(S) = DecisionRule$

```
function LearnRule(S)  
  Cond = True  
  while Impurity(S, Cond) > 0 do  
     $L_{opt} = \arg \min_L \text{Impurity}(S, \text{Cond} \wedge L)$   
    Cond = Cond  $\wedge$   $L_{opt}$   
  return DecisionRule : IF Cond THEN  $Y = \text{Prediction}(S, \text{Cond})$ 
```

## Napoved pravila $Class(S, Cond)$

$$S_{Cond} = \{(\mathbf{x}, y) \in S : Cond(\mathbf{x}) = True\}$$

Regresija,  $D_Y \subseteq \mathbb{R}$ : povprečje

$$Prediction(S, Cond) = \frac{1}{|S|} \sum_{(\mathbf{x}, y) \in S_{Cond}} y$$

Klasifikacija,  $D_Y = \{v_1, v_2, \dots, v_c\}$ : večinski razred

$$Prediction(S, Cond) = \arg \max_{v \in D_Y} p(Y = v | S_{Cond})$$

## Funkcija nečistoče $Impurity(S, Cond)$

Funkcija nečistoče meri varianco vrednosti ciljne spremenljivke  $Y$  v množici pokritih primerov  $S_{Cond} = \{(\mathbf{x}, y) \in S : Cond(\mathbf{x}) = True\}$ .

Regresija,  $D_Y \subseteq \mathbb{R}$

$$Impurity(S, Cond) = \frac{1}{|S|} \sum_{(\mathbf{x}, y) \in S_{Cond}} (y - \bar{y})^2$$

Klasifikacija,  $D_Y = \{v_1, v_2, \dots, v_c\}$

$$Impurity(S, Cond) = 1 - \max_{v \in D_Y} p(Y = v | S_{Cond})$$

## Prekrivni algoritem $Covering(S) = RuleSet$

Za učenje urejene množice pravil

```
function Covering(S)  
  RuleSet = []  
  while  $S \neq \emptyset$  do  
    Rule = LearnRule(S)  
     $S = S \setminus S_{Rule.Cond}$   
    append Rule to RuleSet  
  return RuleSet
```

### Spremembe za neurejene množice pravil

- V vsaki iteraciji izberemo razred  $v$  za katerega se učimo pravilo
- Posebna varianta  $LearnRule(S, v)$ , ki se uči pravilo za izbran razred  $v$
- $S = S \setminus S_{Rule.Cond} \wedge Y=v$

# Ali lahko prepoznam delfina?

primer	dolzina	skрге	kljun	zob	delfin
x <sub>1</sub>	3	ne	da	veliko	da
x <sub>2</sub>	4	ne	da	veliko	da
x <sub>3</sub>	3	ne	da	malo	da
x <sub>4</sub>	5	ne	da	veliko	da
x <sub>5</sub>	5	ne	da	malo	da
x <sub>6</sub>	5	da	da	veliko	ne
x <sub>7</sub>	4	da	da	veliko	ne
x <sub>8</sub>	5	da	ne	veliko	ne
x <sub>9</sub>	4	da	ne	veliko	ne
x <sub>10</sub>	4	ne	da	malo	ne

# Prva iteracija algoritma *LearnRule(S)*

Na začetku  $Cond = True$ ,  $S = \{x_1, x_2, \dots, x_{10}\}$

$L$	$S_{Cond}$	$p_{da}$	$p_{ne}$	$Impurity(S, Cond)$
$dolzina = 3$	$\{x_1, x_3\}$	1	0	0
$lzina = 4$	$\{x_2, x_6, x_9, x_{10}\}$	0.25	0.75	0.25
$dolzina = 5$	$\{x_4, x_5, x_6, x_8\}$	0.5	0.5	0.5
$skрге = da$	$\{x_6, x_7, x_8, x_9\}$	0	1	0
$skрге = ne$	$\{x_1, \dots, x_5, x_{10}\}$	0.83	0.17	0.17
$kljun = da$	$\{x_1, \dots, x_7, x_{10}\}$	0.625	0.375	0.375
$kljun = ne$	$\{x_8, x_9\}$	0	1	0
$zob = veliko$	$\{x_1, x_2, x_4, x_6, \dots, x_9\}$	0.43	0.57	0.43
$zob = malo$	$\{x_3, x_5, x_{10}\}$	0.67	0.33	0.33



# Prva iteracija algoritma *Covering*( $S$ )

- Izbrano pravilo *IF skрге = da THEN delfin = da*
- $S = \{x_1, \dots, x_5, x_{10}\}$

# Prva iteracija algoritma *LearnRule(S)*, drugič

Na začetku  $Cond = True$ ,  $S = \{x_1, \dots, x_5, x_{10}\}$

$L$	$S_{Cond}$	$p_{da}$	$p_{ne}$	$Impurity(S, Cond)$
$dolzina = 3$	$\{x_1, x_3\}$	1	0	0
$dolzina = 4$	$\{x_2, x_{10}\}$	0.5	0.5	0.5
$dolzina = 5$	$\{x_4, x_5\}$	1	0	0
$kljun = da$	$\{x_1, \dots, x_5, x_{10}\}$	0.83	0.17	0.17
$kljun = ne$	$\emptyset$	$NaN$	$NaN$	$NaN$
$zob = veliko$	$\{x_1, x_2, x_4\}$	1	0	0
$zob = malo$	$\{x_3, x_5, x_{10}\}$	0.67	0.33	0.33

## Druga iteracija algoritma *Covering*( $S$ )

- Trenutna (urejena) množica pravil

*IF skрге = da THEN delfin = ne ELSE*  
*IF zob = veliko THEN delfin = da*

- $S = \{x_3, x_5, x_{10}\}$

# Prva iteracija algoritma $LearnRule(S)$ , tretjič

Na začetku  $Cond = True$ ,  $S = \{x_3, x_5, x_{10}\}$

$L$	$S_{Cond}$	$p_{da}$	$p_{ne}$	$Impurity(S, Cond)$
$dolzina = 3$	$\{x_3\}$	1	0	0
$dolzina = 4$	$\{x_{10}\}$	0	1	0
$dolzina = 5$	$\{x_5\}$	1	0	0
$kljun = da$	$\{x_3, x_5, x_{10}\}$	0.67	0.33	0.33
$kljun = ne$	$\emptyset$	$NaN$	$NaN$	$NaN$

## Tretja iteracija algoritma *Covering*(*S*)

- Trenutna (urejena) množica pravil

*IF skрге = da THEN delfin = ne ELSE*  
*IF zob = veliko THEN delfin = da ELSE*  
*IF dolzina = 4 THEN delfin = ne*

- $S = \{x_3, x_5\}$ , čista množica

### Končna (urejena) množica pravil

*IF skрге = da THEN delfin = ne ELSE*  
*IF zob = veliko THEN delfin = da ELSE*  
*IF dolzina = 4 THEN delfin = ne ELSE*  
*delfin = da*

# Kontrola predsodka in variance

## Velikost množice pravil

- število pravil
- število testov v pravilih

## Kontrola velikosti

- 1 Sprotno rezanje: predčasni izhod iz iteracije *LearnRule*
- 2 Naknadno rezanje: odstranjevanje pravil ali posameznih testov

# Znani algoritmi in implementacije

CN2 (Clark and Nibblet 1987)

Na voljo knjižnica za R.

Ripper (Cohen 1995)

Na voljo v zbirki Weka, za uporabo v R na voljo skozi knjižnico RWeka.