

# Nevronske mreže

Ljupčo Todorovski  
Univerza v Ljubljani, Fakulteta za upravo

April 2018

# Pregled predavanja

## Osnovne definicije

- Nevroni, sinapse in topologija NM
- Funkcija nevrona
- Usmerjene nevronske mreže

## Učni algoritmi

- Delta pravilo in vzratno razširjanje napake
- Kompromis med predsodkom in varianco

## Konvolucijske nevronske mreže

# Nevroni in sinapse


## Gradnika nevronske mreže

- Nevroni: vsak ima stanje  $v$  in izhod  $y$
- Sinapse: povezave med nevroni, ki določajo topologijo nevronske mreže; vsaka ima utež  $w$

## Izvajanje nevronske mreže

- Vhodni podatki spremenijo stanje in izhode izbranih nevronov
- Spremembe nevronov se prenašajo po sinapsah
- Nevron, ob spremembi vhodov na sinapsah, izračuna (spremeni) izhod
- Izračuna se nadaljuje dokler se nevroni (izhodi) ne ustalijo

# Funkcija nevrona



Vektorska notacija:  $\mathbf{x} = (1, x_1, x_2, \dots, x_m)^T$  in  $\mathbf{w} = (w_0, w_1, \dots, w_m)^T$

# Usmerjene (*feed-forward*) nevronske mreže

## Vsaj dve ravni nevronov

- Raven vhodnih nevronov, en nevron za vsako vhodno spremenljivko
- Raven izhodnih nevronov
  - Regresija: en izhodni nevron
  - Klasifikacija: en izhodni nevron za vsak razred
- Nič ali več ravni skritih (*hidden*) nevronov

## Topologija

- Nevroni v isti ravni nepovezani
- Sosednji ravni polno povezani: sinapsa med vsakim nevronom ravni  $l - 1$  in vsakim nevronom ravni  $l$

# Enostavni perceptron za binarno klasifikacijo

## Dve ravni nevronov ( $L = 0$ )


- Raven 0 vhodnih nevronov, funkcije aktivacije  $\phi(v) = v$ 
  - Numerična spremenljivka: en nevron
  - Diskretna spremenljivka z zalogo  $D_X$ :  $|D_X|$  nevronov (0 ali 1)
- Raven 1 izhodnih nevronov, funkcija aktivacije "stopnica"

$$\phi_{step}(v) = \begin{cases} 0 & ; v \leq 0 \\ 1 & ; v > 0 \end{cases}$$

## Še ena verzija linearnega modela za klasifikacijo

$$\hat{y} = \phi_{step}(\mathbf{w}^T \mathbf{x})$$

# Običajni funkciji aktivacije v perceptronu $\phi_{step}$ in $\phi(v) = v$



# Iterativno pravilo za učenje uteži enostavnega perceptrona

$$\Delta \mathbf{w} = \eta (y - \phi_{step}(\mathbf{w}^T \mathbf{x})) \mathbf{x}$$

- V vsaki iteraciji obravnavamo en primer  $e = (\mathbf{x}, y)$
- $\Delta \mathbf{w}$  je sprememba uteži v iteraciji
- $\eta$  je parameter, ki določa hitrost učenja (*learning rate*)
- Začetne vrednosti  $\mathbf{w}$  nastavimo naključno

(Rosenblatt 1962)

Če sta razreda linearno ločljiva,  
algoritem konvergira v končnem številu iteracij.



# Pravilo delta za učenje uteži perceptrona

$$\Delta \mathbf{w} = \eta (y - \phi(\mathbf{w}^T \mathbf{x})) \phi'(v) \mathbf{x}$$

Izračun gradienta za  $E = (y - \hat{y})^2$ ,  $\hat{y} = \phi(v)$ ,  $v = \mathbf{w}^T \mathbf{x} = \sum_k w_k x_k$


$$\begin{aligned} \frac{\partial E}{\partial w_i} &= \frac{\partial E}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial w_i} = \frac{\partial E}{\partial \hat{y}} \frac{\partial \phi(v)}{\partial v} \frac{\partial v}{\partial w_i} \\ &= -2(y - \hat{y}) \phi'(v) \frac{\partial \sum_k w_k x_k}{\partial w_i} \\ &= -2(y - \phi(\mathbf{w}^T \mathbf{x})) \phi'(v) x_i \end{aligned}$$

Posplošitev na učenje iz množice primerov

$$\Delta \mathbf{w} = \eta \sum_{(\mathbf{x}, y) \in S} (y - \phi(\mathbf{w}^T \mathbf{x})) \phi'(v) \mathbf{x}$$

# Sigmoidni funkciji aktivacije v usmerjenih NM

$\phi_{\text{logistic}}(v) = 1/(1 + \exp(-v))$  in  $\phi_{\text{tanh}}(v) = \tanh v$



# Funkcija aktivacije za izhodno raven klasifikacijske NM

$$\phi(v) = \frac{e^v}{\sum_k e^{v_k^{(L+1)}}}$$

# Notacija

## Indeksi ravni nevronov

- 0: raven vhodnih nevronov
- $L + 1$ : raven izhodnih nevronov
- $1, 2, \dots, L$ : ravni skritih nevronov

## Uteži $w$ sinaps ter stanja $v$ in izhodi $y$ nevronov

- $w_{ji}^{(l)}$  utež sinapse med  $j$ -tim nevronom ravni  $l - 1$  in  $i$ -tim nevronom ravni  $l$
- $v_i^{(l)}$  stanje  $i$ -tega nevrona ravni  $l$ ,  $v_i^{(l)} = \sum_j w_{ji}^{(l)} y_j^{(l-1)}$
- $y_i^{(l)}$  izhod  $i$ -tega nevrona ravni  $l$ ,  $y_i^{(l)} = \phi(v_i^{(l)})$

# Posplošeno pravilo delta: raven izhodnih nevronov

$$E = \frac{1}{2} \sum_i (y_i - \hat{y}_i)^2, \hat{y}_i = y_i^{(L+1)} = \phi(v_i^{(L+1)}), v_i^{(L+1)} = \sum_j w_{ji}^{(L+1)} y_j^{(L)}$$

$$\begin{aligned} \frac{\partial E}{\partial w_{ji}^{(L+1)}} &= \frac{\partial E}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial v_i^{(L+1)}} \frac{\partial v_i^{(L+1)}}{\partial w_{ji}^{(L+1)}} \\ &= -(y_i - y_i^{(L+1)}) \phi'(v_i^{(L+1)}) \frac{\partial \sum_k w_{ki}^{(L+1)} y_k^{(L)}}{\partial w_{ji}^{(L+1)}} \\ &= -(y_i - y_i^{(L+1)}) \phi'(v_i^{(L+1)}) y_j^{(L)} \\ \Delta w_{ji}^{(L+1)} &= \eta (y_i - y_i^{(L+1)}) \phi'(v_i^{(L+1)}) y_j^{(L)} \end{aligned}$$

## Posplošeno pravilo delta: ravni skritih nevronov

$$\frac{\partial E}{\partial w_{ji}^{(l)}} = \frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial v_i^{(l)}} \frac{\partial v_i^{(l)}}{\partial w_{ji}^{(l)}} = \frac{\partial E}{\partial y_i^{(l)}} \phi'(v_i^{(l)}) y_j^{(l-1)}$$

Trik za izračun  $\frac{\partial E}{\partial y_i^{(l)}}$  iz  $\frac{\partial E}{\partial y_k^{(l+1)}}$

$$\begin{aligned} \frac{\partial E}{\partial y_i^{(l)}} &= \sum_k \frac{\partial E}{\partial v_k^{(l+1)}} \frac{\partial v_k^{(l+1)}}{\partial y_i^{(l)}} \\ &= \sum_k \frac{\partial E}{\partial y_k^{(l+1)}} \phi'(v_k^{(l+1)}) w_{ik}^{(l+1)} \end{aligned}$$

Pri prehodu iz prve v drugo vrstico še enkrat upoštevamo verižno pravilo.

# Posplošeno pravilo delta: ravni skritih nevronov

$$\Delta w_{ji}^{(l)} = \eta \phi'(v_i^{(l)}) y_j^{(l-1)} \sum_k \frac{\partial E}{\partial y_k^{(l+1)}} \phi'(v_k^{(l+1)}) w_{ik}^{(l+1)}$$

- Iteracija pravila od ravni  $L$  do ravni 1
- Na ravni 1 upoštevamo  $y_i = x_i$ , t.j., vrednost spremenljivke  $X_i$

# Velikost in kontrola velikosti nevronske mreže

## Velikost nevronske mreže

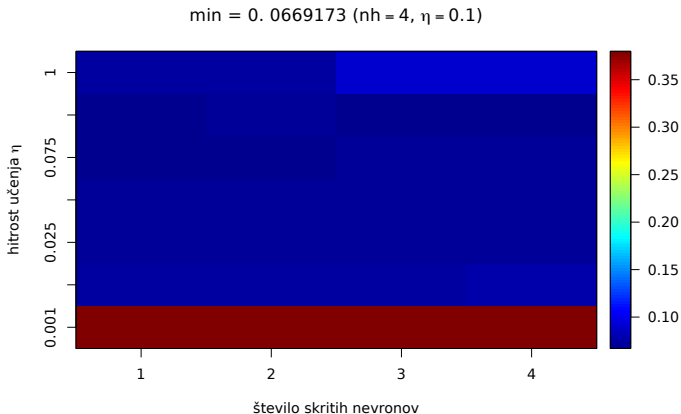
- Večanje nevronske mreže poveča število sinaps
- Torej število prostih parametrov napovednega modela
- Zato se zmanjša predsodek in poveča varianca

## Kontrola velikosti NM

- Število ravni skritih nevronov (globina), globoke (*deep*) NM
- Število skritih nevronov v vsaki ravni




# Klasifikacija z NM: število skritih nevronov ( $nh$ ) in $\eta$




$Y = I((1 + X_1 + X_1X_2)/3 \geq 0.5), D_i = [0, 1], i = 1..2, D_Y = \{0, 1\}$   
 zamenjamo vrednost  $Y$  0.05 naključno izbranim primerom

# Klasifikacija z NM: $nh = 4$




# Raven skritih nevronov in nelinearnost pri klasifikaciji

vhodna raven




raven skritih nevronov (stanja)




# Raven skritih nevronov in nelinearnost pri klasifikaciji


vhodna raven



raven skritih nevronov (izhodi)




# Regresija z NM: število skritih nevronov ( $nh$ ) in $\eta$



$$Y = (1 + X_1 + X_1 X_2)/3 + \mathcal{N}(0, 0.05), D_i = [0, 1], i = 1..2, D_Y = [0, 1]$$

# Regresija z NM: $nh = 1$



# Raven konvolucije (*convolution*)

## Notacija


- Raven  $l - 1$  organizirana v obliki matrike nevronov dimenzij  $x \times y$
- Uteži  $w_0$  in konvolucijska matrika dimenzij  $c \times c$ , elementi  $w_{i,j}$
- Raven  $l$  organizirana v obliki matrike nevronov dimenzij  $(x - c + 1) \times (y - c + 1)$

## Konvolucija, uporabljena namesto običajne obtežene vsote

$$v_{i,j}^{(l)} = w_0 + \sum_{k=1}^c \sum_{l=1}^c w_{k,m} y_{i+k-1,j+m-1}^{(l-1)}$$

- $y_{i,j}^{(l-1)}$  in  $v_{i,j}^{(l)}$  so izhodi in stanja nevronov na ravni  $l - 1$  oz.  $l$
- Običajna vrednost  $c = 5$

# Raven konvolucije: grafični prikaz





# Raven akumulacije (*pooling*)

## Notacija

- Raven  $l - 1$  organizirana v obliki matrike nevronov dimenzij  $x \times y$
- Raven  $l$  organizirana v obliki matrike nevronov dimenzij  $x/a \times y/a$
- Predpostavka:  $a|x$  in  $a|y$


max-akumulacija, uporabljena namesto običajne obtežene vsote

$$v_{i,j}^{(l)} = \max \left\{ y_{(i-1) \cdot a + 1, (j-1) \cdot a + 1}^{(l-1)}, \dots, y_{i \cdot a, j \cdot a}^{(l-1)} \right\}$$


- $y_{i,j}^{(l-1)}$  in  $v_{i,j}^{(l)}$  so izhodi in stanja nevronov na ravni  $l - 1$  oz.  $l$
- Običajna vrednost  $a = 2$

# Raven akumulacije: grafični prikaz

*Raven nevronov l-1 (običajno izhodna raven konvolucije)*




*Raven nevronov l*




# Običajna topologija: $r \times$ konvolucija $\rightarrow r \times$ akumulacija

Široka uporaba za klasifikacijo slik in razpoznavanje z roko napisnih številk.



# Razpoznavanje na roko napisanih števil

- Klasifikacijska napaka klasičnih metod: okoli 3%
- Klasifikacijska napaka konvolucijskih NM: manj kot 0.5%



# Posebnosti učenja nevronske mreže

- Običajno je opraviti normalizacijo podatkov
- Težave z gradientno metodo in lokalnimi ekstremi
- Večkratni izračuni, stohastične metode
- Funkcije aktivacije prilagojene problemu

# Znani algoritmi in implementacije

## Originalni predlog (Rosenblatt 1962)

Iterativno pravilo za klasifikacijo z enostavnim perceptronom.

## Nadgradnja (Hinton 1986)

Vzvratno razširjanje napake, knjižnica nnet za R.

## Globoko učenje (Hinton in ost. 2006)

Knjižnica TensorFlow, različne druge: tudi mxnet za R.