

Napredno strojno učenje

Izbrana poglavja računalniške matematike

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za upravo
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Februar 2019

Spremenljivke

Napovedne (vhodne, neodvisne) spremenljivke (atributi) $X_i, i = 1..p$

- Urejena p -terica $\mathbf{X} = (X_1, X_2, \dots, X_p)$
- Zaloge vrednosti spremenljivk D_1, D_2, \dots, D_p
 - X_i je numerična (zvezna, kvantitativna), če $D_i \subseteq \mathbb{R}$
 - X_i je diskretna (kvalitativna), če je D_i končna in običajno neurejena

Ciljna (izhodna, odvisna) spremenljivka Y

Zaloga vrednosti D_Y

Primeri

Učni primer

$e \in \times_{i=1}^p D_i \times D_Y$ oziroma

$$e = (\mathbf{x}, y) = (x_1, x_2, \dots, x_p, y), x_i \in D_i, y \in D_Y$$

Podatkovna množica učnih primerov $S \subseteq \mathcal{E}$

\mathcal{E} označuje množico vseh možnih primerov, imenujemo jo tudi domena

$$\mathcal{E} = \times_{i=1}^p D_i \times D_Y$$

Opomba o notaciji

$$\times_{i=1}^p D_i = D_1 \times D_2 \times \dots \times D_p$$

Ilustrativni primer: Kartica zvestobe

Primeri (vrstice) so kupci, spremenljivke (stolpci) lastnosti kupcev

Ime	Prihodki	Starost	Spol	Letna poraba	Dober kupec
Mojca	1,890	32	Ž	18,200	da
Janez	1,200	48	M	8,900	ne
Špela	900	63	Ž	9,200	da

Primeri so nakupi, spremenljivke kupec in produkti

Kupec	Spol	Pivo	Plenice	Voda	Kruh	Čokolada
Mojca	Ž	0	0	0	2	3
Janez	M	2	2	0	1	0

Rezultat učenja: Model

Model je funkcija m

$$m : \bigtimes_{i=1}^p D_i \rightarrow D_Y$$

Za podane vrednosti napovednih spremenljivk $\mathbf{x} = (x_1, x_2, \dots, x_p)$ vrne model m ocenjeno (napovedano) vrednost ciljne spremenljivke $\hat{y} = m(x_1, x_2, \dots, x_p) = m(\mathbf{x})$

Ilustrativni primeri: kartica zvestobe

- *Dober kupec* = $m(\text{Starost}, \text{Prihdoki}, \text{Spol})$
- *Letna poroaba* = $m(\text{Starost}, \text{Spol})$
- *Pivo* = $m(\text{Spol}, \text{Plenice})$

Definicija naloge nadzorovanega strojnega učenja

Definicija naloge

- Na osnovi podane učne podatkovne množice S_{train}
- Najdi model m , ki je **točen** in **splošno veljaven**

Točen in splošno veljaven model

Točen model doseže **minimalno napako** (maksimalno točnost) na učni množici S_{train} , splošno veljaven pa doseže **majhne napake** na poljubni podatkovni množici S .

Vrednotenje zmogljivosti modela

Funkcija izgube meri napako modela na enem primeru

$$L : D_Y \times D_Y \rightarrow \mathbb{R}_0^+$$

Vrne razliko $L(y, \hat{y})$ med opazovano (y) in napovedano (\hat{y}) vrednostjo ciljne spremenljivke Y na enem primeru.

Merjenje napake modela m na podatkovni množici S

$$Err : \left(\bigtimes_{i=1}^p D_i \rightarrow D_Y \right) \times \mathcal{P}(\mathcal{E}) \rightarrow \mathbb{R}_0^+$$

$$Err(m, S) = \frac{1}{|S|} \sum_{(\mathbf{x}, y) \in S} L(y, m(\mathbf{x}))$$

Povprečna vrednost funkcije izgube modela m na primerih iz množice S .

Napaka modela pri regresiji, $D_Y \subseteq \mathbb{R}$

Običajna funkcija izgube je **kvadratna napaka**

$$L_{SE}(y, \hat{y}) = (y - \hat{y})^2$$

Napaka modela

S to funkcijo izgube vrednotimo srednjo kvadratno napako $MSE = Err$ modela. Pogosto računamo tudi celotno napako $RMSE = \sqrt{MSE}$.

Napaka modela pri razvrščanju, D_Y je končna množica

Običajna funkcija izgube

$$L_{01}(y, \hat{y}) = \mathbb{I}(y \neq \hat{y}) = \begin{cases} 1; & y \neq \hat{y} \\ 0; & y = \hat{y} \end{cases}$$

Napaka modela

S to funkcijo izgube vrednotimo klasifikacijsko napako, $Err \in [0, 1]$ modela (običajno v odstotkih). Pogosto računamo tudi klasifikacijsko točnost (ne natančnost) $Acc = 1 - Err$.

Algoritem za nadzorovano strojno učenje

$$\mathcal{A} : \mathcal{P}(\mathcal{E}) \rightarrow \left(\bigtimes_{i=1}^p D_i \rightarrow D_Y \right)$$

Na osnovi podane učne množice S_{train} , algoritem vrne model m za ocenjevanje (napovedovanje) vrednosti ciljne spremenljivke Y iz podanih vrednosti napovednih spremenljivk X_1, X_2, \dots, X_p , t.j.,

$$m = \mathcal{A}(S_{train})$$

Algoritmi za nadzorovano strojno učenje

- Linearni: linearna in logistična regresija
- Metoda najbližjih sosedov
- Odločitvena drevesa in pravila
- Metode podpornih vektorjev in jedra
- Umetne nevronske mreže
- Metode ansamblov

Priporočena priprava za nadaljevanje

Če niste poslušali predmeta ITAP

- Prosojnice predavanj pri predmetu kt.ijs.si/~ljupco/lectures/itap/
- Prosto-dostopni učbenik ISL www-bcf.usc.edu/~gareth/ISL/

Pregled vsebin

Štirje tematski sklopi naprednega strojnega učenja

- 1 Učenje iz podatkovnih tokov
- 2 Meta učenje
- 3 Upoštevanje predznanja pri strojnem učenju
- 4 Razno, v glavnem (globoke) umetne nevronske mreže

Način izvajanja predmeta

Tematski sklop

- Trajanje: 3-4 tedne, 9-12 ur predavanj in seminarjev, 6-8 ur vaj
- Najprej 2-3 tedne predavanj: 6-9 ur
- Zadnji teden seminarji: 3 ure

Vsebina predavanj in seminarjev

- Predavanja: predstavitev tematskega sklopa, fokus na algoritmih
- Seminarji: pregled tekočih raziskav in odprtih vprašanj

Ocenjevanje

Tri domače naloge (60 točk)

- Na koncu vsakega od prvih treh sklopov domača naloga
- Predstavljena na zadnjih vajah v okviru sklopa
- Vsaka naloga vredna 20 točk
- Običajni rok za oddajo: dva tedna po predstavitvi
- Pozitivno opravljene domače naloge: več kot 30 točk

Ustni izpit (40 točk)

- Pogoji za pristop so pozitivno opravljene domače naloge
- Pozitivno opravljen izpit: več kot 20 točk
- Del izpita se da nadomestiti s seminarsko nalogo: razvoj algoritma (do 20 točk) ali aplikacija (do 10 točk)

Učenje iz podatkovnih tokov

Izvajalec Aljaž Osojnik, IJS in FMF, www.fmf.uni-lj.si/si/imenik/48599/

- Trajanje 3 tedne: 2 tedna (6 ur) predavanj, 1 teden (3 ure) seminarji, 3 tedne (6 ur) vaj
- Strukturo bo predstavil sam na prvih predavanjih

Vsebina

- Podatkovni tok: primeri prihajajo v kratkih časovnih intervalih
- Kako prilagoditi algoritme: izračun ustreznih statistik
- Kako vrednotiti (spreminjajoče se) modele?

Meta učenje

Struktura

- Trajanje 3 tedne: enako kot prej
- Prva predavanja: naloge meta učenja
- Druga predavanja: AutoML in surogati
- Seminarji: nadgradnje surogatov in AutoML

Vsebina

- Meta učenje: učenje o učenju
- Napovedovanje zmogljivosti algoritmov na podani množici
- AutoML: avtomatsko nastavljanje parametrov algoritmov
- Meta učenje in globoke nevronske mreže
- Surogati: pristop k optimizaciji z učenjem približka ciljne funkcije

Upoštevanje predznanja pri strojnem učenju

Struktura

- Trajanje 4 tedne: 3 tedne predavanj, 1 teden seminarjev, 4 tedne vaj
- Prva predavanja: odkrivanje navadnih in diferencialnih enačb
- Druga predavanja: predznanje v logiki prvega reda
- Tretja predavanja: taksonomije in strojno učenje (Jan Kralj)
- Seminarji: predznanje in globoke nevronske mreže

Vsebina

- Simbolična regresija in odkrivanje enačb iz predznanja in podatkov
- Induktivno logično programiranje in relacijsko učenje
- Odločitvena drevesa za napovedovanje in razvrščanje
- Taksonomije in strojno učenje

Razno

Struktura

- Trajanje 4 tedne: 2 tedna predavanj, 2 tedna seminarjev, 3 tedne vaj
- Prva predavanja: globoke nevronske mreže in ciljne funkcije, enačbe
- Druga predavanja: še nedoločeno (avto-inkoderji, vstavitve, delno nadzorovano učenje)
- Seminarji: nadgradnja globokih nevronskih mrež

Vsebina

- Alternativne ciljne funkcije in vzvratno razširjanje napake
- Umetne nevronske mreže in diferencialne enačbe
- Še nedoločeno (avto-inkoderji, delno nadzorovano učenje)

Izvajalci in literatura

Izvajalci

- Predavanja in seminarji: Ljupčo Todorovski in Aljaž Osojnik
- Vaje: Jan Kralj in Aljaž Osojnik
- Domače naloge: Jan Kralj, Aljaž Osojnik in Ljupčo Todorovski
- Ustni izpit (seminarska naloga): Ljupčo Todorovski

Literatura

- Za vsak sklop posebej
- Za predavanja učbeniki in članki
- Za seminarje članki
- Članki bodo dostopni v spletni učilnici

Definicija naloge

Za podane

- Algoritme strojnega učenja $\mathcal{A} = \{A_1, A_2, \dots, A_m\}$
- Podatkovne množice $\mathcal{S} = \{S_1, S_2, \dots, S_n\}$, $S_i \in \mathcal{E}_i$
- Metodo vrednotenja zmogljivosti $p : \mathcal{A} \times \mathcal{S} \rightarrow \mathbb{R}$

Odgovori na vprašanje

Ali so zmogljivosti algoritmov iz \mathcal{A} statistično značilno različne?

Primeri metode p

Točnost izračunana s 100-kratnim zankanjem.
Ploščina AUROC izračunana z 10-kratnim prečnim preverjanjem

Od zmogljivosti p do rangov r

	A_1	A_2	\dots	A_m			A_1	A_2	\dots	A_m
S_1	p_{11}	p_{12}	\dots	p_{1m}	\rightarrow	S_1	r_{11}	r_{12}	\dots	r_{1m}
S_2	p_{21}	p_{22}	\dots	p_{2m}		S_2	r_{21}	r_{22}	\dots	r_{2m}
\vdots			\ddots	\vdots		\vdots			\ddots	\vdots
S_n	p_{n1}	p_{n2}	\dots	p_{nm}		S_n	r_{n1}	r_{n2}	\dots	r_{nm}

$$p_{ij} = p(A_j, S_i)$$

$$r_{ij} = \text{rang}(p_{ij}, \{p_{i1}, p_{i2}, \dots, p_{im}\})$$

Navaden rang

$$\text{rang} : \mathbb{R} \times \mathcal{P}(\mathbb{R}) \rightarrow \mathbb{N}$$

- Rangi elementov večkratne množice $V = \{v_1, v_2, \dots, v_s\}$, $\text{rang}(v_1, V)$, $\text{rang}(v_2, V)$, \dots , $\text{rang}(v_s, V)$ so permutacija naravnih števil od 1 do $s = |V|$ za katero velja $\text{rang}(v_i) < \text{rang}(v_j) \iff v_i > v_j$
- Primer $\text{rang}(3, \{2, 1, 3, 2\})$ je 1, $\text{rang}(2, \{2, 1, 3, 2\})$ je pa 2 oziroma 3.

Povprečen rang

$$\text{rang}_{avg} : \mathbb{R} \times \mathcal{P}(\mathbb{R}) \rightarrow \mathbb{Q}$$

- Za elemente V , ki se pojavijo v množici q krat, je

$$\text{rang}_{avg}(v, V) = \frac{1}{q} \sum_{v_i \in V: v_i = v} \text{rang}(v_i, V)$$

- Primer $\text{rang}_{avg}(3, \{2, 1, 3, 2\}) = 1$, $\text{rang}(2, \{2, 1, 3, 2\}) = (2 + 3)/2$.

Konkreten primer, $n = 25$, $m = 3$

	RF	Tree	NN
abalone	0.784774	0.775198	0.774240
adult	0.849720	0.853610	0.839380
aileron	0.874545	0.858400	0.869964
bank32nh	0.805908	0.758301	0.698486
boston	0.887352	0.859684	0.861660
car	0.977431	0.946759	0.993056
.			.
.			.
nursery	1.000000	1.000000	1.000000
musk	0.999697	0.999697	0.995605
puma8NH	0.831299	0.825562	0.806274
puma32H	0.880249	0.863037	0.607666
quake	0.530762	0.555096	0.548209
rmftsa_sleepdata	0.705078	0.744141	0.730469
segment	0.998268	0.990909	0.996537
splice	0.968025	0.945141	0.833229
spectrometer	0.962335	0.949153	0.928437
vowel	0.993939	0.987879	1.000000
waveform-5000	0.888200	0.822600	0.855800
wind	0.865075	0.831305	0.845908

	RF	Tree	NN
abalone	1	2	3
adult	2	1	3
aileron	1	3	2
bank32nh	1	2	3
boston	1	3	2
car	2	3	1
.			.
.			.
nursery	2	2	2
musk	1.5	1.5	3
puma8NH	1	2	3
puma32H	1	2	3
quake	3	1	2
rmftsa_sleepdata	3	1	2
segment	1	3	2
splice	1	2	3
spectrometer	1	2	3
vowel	2	3	1
waveform-5000	1	3	2
wind	1	3	2
Povprečje	1.46	2.22	2.32

Wilcoxonov test predznačenih rangov: Kaj opazujemo?

Razlike v zmogljivosti algoritmov A_1 in A_2

$$d_i = p_{i1} - p_{i2}$$

- $\text{sgn}(d_i) = 1$, A_1 bolj zmogljiv od A_2
- $\text{sgn}(d_i) = -1$, A_2 bolj zmogljiv od A_1
- $\text{sgn}(d_i) = 0$, A_1 in A_2 sta enako zmogljiva

Porazdelitev vrednosti rangov $r(|d_i|)$

- Rangi absolutnih vrednosti $r(|d_i|) = \text{rang}(|d_i|, \{|d_1|, |d_2|, \dots, |d_n|\})$
- Statistiki $R^+ = \sum_{i=1}^n Z_i r(|d_i|)$ in $R^- = \sum_{i=1}^n (1 - Z_i) r(|d_i|)$
- Naključne spremenljivke $Z_i = \mathbb{I}(d_i > 0)$, $i = 1 \dots n$

Predpostavke in ničelna hipoteza

Predpostavke

- Razlike d_i medsebojno neodvisne
- Porazdelitvi obeh vzorcev p_{1i} in p_{2i} sta zvezni
- Porazdelitev razlik je simetrična

Ničelna hipoteza: A_1 in A_2 sta enako zmogljiva

$$H_0 : \theta_d = 0$$

θ_d je mediana vrednosti d_i

Porazdelitev Z_i ob predpostavki H_0

$$Z_i \stackrel{H_0}{\sim} \text{Bernoulli}\left(\frac{1}{2}\right)$$

$$E[Z_i | H_0] = \frac{1}{2}$$

$$\text{Var}[Z_i | H_0] = \frac{1}{4}$$

Približna porazdelitev R^+ ob predpostavki H_0

Izpeljavi na tabli

$$\begin{aligned}E[R^+|H_0] &= \frac{1}{4}n(n+1) \\ \text{Var}[R^+|H_0] &= \frac{1}{24}n(n+1)(2n+1)\end{aligned}$$

Po centralnem limitnem izreku $W \sim N(0, 1)$

$$W = \frac{R^+ - \frac{1}{4}n(n+1)}{\sqrt{\frac{1}{24}n(n+1)(2n+1)}}$$

Eksaktna porazdelitev R^+ ob predpostavki H_0

$$P(R^+ = k | H_0) = \frac{u_n(k)}{2^n}$$

- $u_n(k)$ je število n -teric vrednosti Z_i , (z_1, z_2, \dots, z_n) za katere velja $R^+ = k$
- Kako preštejemo število n -teric $u_n(k)$

Preprosta rekurzija

- Razlikam d_1, d_2, \dots, d_{n-1} dodamo d_n
- Brez škode za splošnost predpostavimo $r(|d_n|) = n$
- Če $d_n < 0$, ostane R^+ nespremenjen
- Če $d_n > 0$, se R^+ poveča za n

Eksaktna porazdelitev R^+ ob predpostavki H_0 , nadaljevanje

$$\begin{aligned} P(R^+ = k | H_0) &= \frac{u_n(k)}{2^n} = \frac{u_{n-1}(k)}{2^{n-1}} P(d_n < 0) + \frac{u_{n-1}(k - n)}{2^{n-1}} P(d_n > 0) \\ &= \frac{u_{n-1}(k) + u_{n-1}(k - n)}{2^n} \end{aligned}$$

- Velja torej $u_n(k) = u_{n-1}(k) + u_{n-1}(k - n)$
- Za $n = 1$ velja $u_1(0) = u_1(1) = 1$, sicer pa $u_1(k) = 0$

Je porazdelitev R^+ simetrična?

Enostavno pokazati, da

$$P(R^+ - \frac{1}{4}n(n+1) \geq k | H_0) = P(R^+ - \frac{1}{4}n(n+1) \leq -k | H_0)$$

Namig: Pod predpostavko H_0 , sta vrednosti Z_i in $1 - Z_i$ enako verjetni

Kaj pa porazdelitev R^- ?

Je enaka porazdelitvi R^+ , izpeljava na tabli

$$P(R^+ \leq k | H_0) = P(R^- \leq k | H_0)$$

Enostranski Wilcoxonov test predznačenih rangov

Alternativna hipoteza: A_1 je bolj zmogljiv od A_2

$$H_A : \theta_d > 0$$

- H_0 zavrnamo, če je vrednost R^- majhna
- Bolj natančno, če $R^- \leq t_\alpha$
- t_α je največje naravno število za katero še velja $P(R^- \leq t_\alpha | H_0) \leq \alpha$

Dvostranski Wilcoxonov test predznačenih rangov

Alternativna hipoteza: A_1 in A_2 nista enako zmogljiva

$$H_A : \theta_d \neq 0$$

- H_0 zavrnamo, če je ena od vrednosti R^+ in R^- majhna
- Bolj natančno, če $\min(R^+, R^-) \leq t_{\alpha/2}$
- t_α je največje naravno število za katero še velja $P(\min(R^+, R^-) \leq t_{\alpha/2} | H_0) \leq \alpha/2$

Friedmanov test: Kaj opazujemo?

Povprečne range za vsako podatkovno množico S_i

$$r_{ij} = \text{rang}(p_{ij}, \{p_{i1}, p_{i2}, \dots, p_{im}\})$$

Povprečje povprečnih rangov

$$\bar{r}_j = \frac{1}{N} \sum_{i=1}^n r_{ij}$$

Predpostavke in ničelna hipoteza

Predpostavke

- Opazovanja za različne podatkovne množice so neodvisne
- Porazdelitev opazovanj je zvezna
- Opazovanja za različne podatkovne množice se lahko razlikujejo le v lokacijskem parametru Δ (povprečju ali mediani)

Ničelna hipoteza: vsi algoritmi so enako zmogljivi

$$H_0 : \Delta_1 = \Delta_2 = \dots \Delta_m$$

Δ_i je lokacijski parameter porazdelitve opazovanj za podatk. množico S_i

Statistika porazdelitve povprečij povprečnih rangov

Varianca povprečij povprečnih rangov

$$\chi_r^2 = \frac{12n}{m(m+1)} \sum_{j=1}^m (\bar{r}_j - \bar{r})^2$$

Povprečje povprečij povprečnih rangov

$$\begin{aligned}\bar{r} &= \frac{1}{m} \sum_{j=1}^m \bar{r}_j = \frac{1}{mn} \sum_{j=1}^m \sum_{i=1}^n r_{ij} = \frac{1}{mn} \sum_{i=1}^n \sum_{j=1}^m r_{ij} \\ &= \frac{1}{mn} \sum_{i=1}^n \frac{1}{2} m(m+1) = \frac{1}{2mn} nm(m+1) \\ &= \frac{1}{2} (m+1)\end{aligned}$$

Statistika porazdelitve povprečij povprečnih rangov, nad.

$$\chi_r^2 = \frac{12n}{m(m+1)} \sum_{j=1}^m (\bar{r}_j - \frac{1}{2}(m+1))^2$$

Friedmanov test, dvosmerna analiza variance z rangi

Alternativna hipoteza: Algoritmi so različno zmogljivi

$$H_A : \exists j, j' \in \{1, 2, \dots, m\} : \Delta_j \neq \Delta_{j'}$$

- H_0 zavrnamo, če je varianca povprečij visoka
- Bolj natančno, če $\chi_r^2 \geq c_\alpha$
- c_α je največje število, za katero še velja $P(\chi_r^2 \leq c_\alpha) \leq \alpha$

Friedmanov test: približna statistika

$$F = \frac{(n-1)\chi_r^2}{n(m-1) - \chi_r^2}$$

- Porazdelitev $F(m-1, (m-1)(n-1))$

Zapleti in popravki, ki jih ne obravnavamo tukaj

Enake zmogljivosti, kar je pri zveznih porazdelitvah $p = 0$

- $\exists i : d_i = 0$
- $\exists i, j, j' : p_{ij} = p_{ij'}$

In kaj če ničelno hipotezo zavrnamo?

Post-hoc testi

Katere razlike po parih algoritmov so povzročile zavračanje?

Dve vrsti post-hoc testov

- 1 Vsi-z-enim: V fokusu en algoritem, $m - 1$ testov
- 2 Vsi-z-vsemi: Vsi algoritmi, $m(m - 1)/2$ testov

Vsi-z-enim: Bonferroni-Dunn test

$$z = \frac{|\bar{r}_j - \bar{r}_{j'}|}{\sqrt{\frac{m(m+1)}{6n}}}$$

- Vrednosti z so porazdeljene po $N(0, 1)$
- Izračunamo vrednost $p = 2P(N(0, 1) > |z|)$
- Če je $p < \alpha$, zavrnamo ničelno hipotezo, da je algoritem A_j enako zmogljiv kot kontrolni algoritem $A_{j'}$

Vsi-z-vsemi: Nemenyi test

$$CD = q_{\alpha} \sqrt{\frac{m(m+1)}{12n}}$$

- Kritična razdalja CD : razlika med zmogljivostmi dveh algoritmov A_j in $A_{j'}$ je statistično značilna, če $|p_{ij} - p_{ij'}| > CD$
- q_{α} je kritična vrednost Studentove porazdelitve rangov

Konkreten primer, $n = 25$, $m = 3$, nadaljevanje

Fisherjev test


- Vrednost statistike 11.82, vrednost $p = 0.002713$
- $p < 0.01$: ničelno hipotezo, pri stopnji zaupanja 99%, zavrnamo
- Torej so razlike med algoritmi statistično značilne

Post-hoc Nemenyi test

$$CD = 0.6768776$$

Razlika med zmogljivostmi dveh algoritmov je statistično značilna, če se njihovi povprečni povprečnih rangov razlikujeta za več kot 0.6768776.

Konkreten primer, diagram povprečja povprečnih rangov



Literatura in odprta vprašanja

Literatura

- Predavanje: članek (Demšar 2006, JMLR)
- Predavanje: magistrska naloga Lare Dular, poglavje 3

Tekoče raziskave in odprta vprašanja

- Kaj če primerjamo po več kot en mero zmogljivosti?
- Seminar: magistrska naloga Lare Dular, poglavja 4 in 5
- Kaj pa Bayesov pristop?
- Seminar: članek-vadnica (Benavoli in ost. 2018, JMLR)

Praktični napotki

Implementacija v R

- Paket *scmamp*
- Kratka vadnica cran.r-project.org/web/packages/scmamp/vignettes/Statistical_assessment_of_the_differences.html

Podatki o zmogljivosti algoritmov na različnih množicah

- Spletna stran in repozitorij openml.org
- Paket za R *OpenML*